

PENGARUH TONE KULIT TERHADAP KLASIFIKASI JERAWAT PADA ARSITEKTUR SMALL VGGNET

LAPORAN TUGAS AKHIR

Oleh:

M. Benando Banda Pangestu

105216019



**FAKULTAS SAINS DAN ILMU KOMPUTER
PROGRAM STUDI ILMU KOMPUTER
UNIVERSITAS PERTAMINA
JANUARI 2020**

PENGARUH TONE KULIT TERHADAP KLASIFIKASI JERAWAT PADA ARSITEKTUR SMALL VGGNET

LAPORAN TUGAS AKHIR

Oleh:

M. Benando Banda Pangestu

105216019



**FAKULTAS SAINS DAN ILMU KOMPUTER
PROGRAM STUDI ILMU KOMPUTER
UNIVERSITAS PERTAMINA
JANUARI 2020**



Universitas
Pertamina

LEMBAR PENGESAHAN

Judul Tugas Akhir : Pengaruh Tone Kulit Terhadap Klasifikasi Jerawat
pada Arsitektur Small VGGNet
Nama Mahasiswa : M. Benando Banda Pangestu
Nomor Induk Mahasiswa : 105216019
Program Studi : Ilmu Komputer
Fakultas : Sains dan Ilmu Komputer
Tanggal Lulus Sidang Tugas Akhir : 15 Januari 2020

Jakarta, 29 Januari 2020

MENGESAHKAN

Pembimbing I

Pembimbing II

Ade Irawan, Ph.D.
NIP.116xxx

Pembimbing Dua
NIP.116xxx

MENGETAHUI,

Ketua Program Studi

Nama Kaprodi

NIP. 116xxx

LEMBAR PERNYATAAN

Dengan ini saya menyatakan bahwa Tugas Akhir berjudul Pengaruh Tone Kulit Terhadap Klasifikasi Jerawat pada Arsitektur Small VGGNet ini adalah benar-benar merupakan hasil karya saya sendiri dan tidak mengandung materi yang ditulis oleh orang lain kecuali telah dikutip sebagai referensi yang sumbernya telah dituliskan secara jelas sesuai dengan kaidah penulisan karya ilmiah.

Apabila dikemudian hari ditemukan adanya kecurangan dalam karya ini, saya bersedia menerima sanksi dari Universitas Pertamina sesuai dengan peraturan yang berlaku.

Demi pengembangan ilmu pengetahuan, saya menyetujui untuk memberikan kepada Universitas Pertamina hak bebas royalti noneksklusif (*non-exclusive royalty-free right*) atas Tugas Akhir ini beserta perangkat yang ada. Dengan hak bebas royalti noneksklusif ini Universitas Pertamina berhak menyimpan, mengalih media/format-kan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan mempublikasikan Tugas Akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya

Jakarta, 29 Januari 2020

Yang membuat pernyataan,

M. Benando Banda Pangestu

ABSTRAK

M. Benando Banda Pangestu. 105216019. Pengaruh Tone Kulit Terhadap Klasifikasi Jerawat pada Arsitektur Small VGGNet.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Kata kunci: Tuli, Bahasa isyarat, Bisindo, Machine learning, ASL, Transfer learning, Parameter transfer.

ABSTRACT

M. Benando Banda Pangestu. 105216019. The Effect of skin tones to the classification of Face acne on Small VGGNet architecture.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Keywords: Deaf, Sign language, Bisindo, Machine learning, ASL, Transfer Learning, Parameter transfer.

KATA PENGANTAR

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Jakarta, 29 Januari 2020

Riestiya Zain Fadillah

DAFTAR ISI

ABSTRAK	i
ABSTRACT	ii
KATA PENGANTAR	iii
DAFTAR ISI	iv
DAFTAR TABEL	vi
DAFTAR GAMBAR	vii
BAB I PENDAHULUAN	2
1.1 Latar Belakang	2
1.2 Rumusan Masalah	3
1.3 Hipotesis	3
1.4 Batasan Masalah	3
1.5 Tujuan Penelitian	3
1.6 Manfaat Penelitian	3
BAB II TINJAUAN PUSTAKA	5
2.1 Jerawat	5
2.2 Machine Learning	5
2.2.1 Supervised Learning	5
2.2.2 Image Processing	6
2.2.3 Convolutional Neural Network(CNN)	6
2.2.4 VGGNet	6
2.3 Confusion Matrix	6
BAB III METODE PENELITIAN	8
BAB IV HASIL DAN PEMBAHASAN	11

4.1	Dataset	11
4.2	Training model	11
4.3	Hasil Klasifikasi	14
4.3.1	Whitehead/Komedo putih	14
4.3.2	Blackhead/Komedo Hitam	15
4.3.3	Cyst/Kista	16
4.3.4	Papula	17
4.3.5	Pustula	19
BAB V	KESIMPULAN DAN SARAN	22
5.1	Kesimpulan	22
5.2	Saran	22
	DAFTAR PUSTAKA	24
	LAMPIRAN A Empirical Binary Entropies for Given Bit-Flipping Probabilities	26

DAFTAR TABEL

DAFTAR GAMBAR

Gambar 3.1	Diagram proses penelitian.	8
Gambar 4.1	Diagram sistem.	11
Gambar 4.2	Nilai akurasi pada training dan Testing set.	12
Gambar 4.3	F1 Score pada training dan Testing set.	13
Gambar 4.4	Hasil deteksi Komedo Putih pada kulit terang.	14
Gambar 4.5	Hasil deteksi Komedo Putih pada kulit gelap.	14
Gambar 4.6	Hasil deteksi Komedo hitam pada kulit terang.	15
Gambar 4.7	Hasil deteksi Komedo hitam pada kulit putih.	16
Gambar 4.8	Hasil deteksi Kista pada kulit terang.	16
Gambar 4.9	Hasil deteksi kista pada kulit gelap.	17
Gambar 4.10	Hasil deteksi Papula pada kulit terang.	17
Gambar 4.11	Hasil deteksi papula pada kulit gelap.	18
Gambar 4.12	Hasil deteksi pustula pada kulit terang.	19
Gambar 4.13	Hasil deteksi pustula pada kulit gelap.	19
Gambar A.1	System setup for obtaining p_{ABC}	26



BAB I

PENDAHULUAN

1.1 Latar Belakang

Kulit merupakan bagian terluar dari tubuh manusia. Merawat serta menjaga kesehatan kulit merupakan hal yang penting bagi manusia karena kulit memberikan perlindungan terhadap sinar UV dan bahan kimia berbahaya. Kulit juga memiliki peran lain seperti menjadi pengatur suhu tubuh, pertahanan imunitas, serta tempat membuang racun dan zat yang tidak dibutuhkan pada tubuh melalui kelenjar keringat. Jika kulit tidak dirawat, racun atau zat yang tidak diperlukan tubuh dapat tertinggal di kulit sehingga dapat menyebabkan hal yang tidak diinginkan. Kulit juga memiliki warna atau tone yang berbeda di tiap suku bangsa. Bangsa Afrika memiliki kulit lebih gelap, bangsa Eropa/Kaukasia memiliki kulit putih terang, sedangkan bangsa Asia memiliki kulit yang beragam dari coklat hingga putih terang [Jablonski (2004)]

Kulit adalah bagian tubuh yang paling sering bertemu dengan debu dan kotoran. Karena itu, pori-pori kulit bisa tertutup dan kotoran tersebut dapat menumpuk yang akhirnya menghasilkan jerawat. Masyarakat pun belum begitu mengerti cara mengatasi jerawat dengan baik dan benar. Penanganan jerawat yang salah dapat menghasilkan luka pada muka dan akan menimbulkan ketidaknyamanan [McGrath et al. (2004)].

Jerawat adalah sebuah penyakit kulit yang mempengaruhi kelenjar minyak pada kulit, dan dapat menghasilkan peradangan pada kulit yang terpengaruh dengan jerawat. Dokter biasanya melakukan deteksi jerawat dengan mengecek langsung kulit pasien atau melihat foto yang diberikan oleh pasien. Metode ini dapat dibilang adalah metode yang memakan waktu, dikarenakan pasien harus menunggu hasil dari dokter yang melakukan pengecekan terhadap jerawat mereka. Selain itu, proses ini juga berat terhadap dokter yang melakukan dikarenakan dibutuhkannya usaha yang sangat besar [Williams et al. (2012)].

Pada saat ini deteksi jerawat masih dilakukan secara manual, dengan datang ke dokter untuk mendapatkan diagnosis awal tentang jerawat apa yang sedang muncul di kulit muka masing-masing. Cara itu sendiri memakan banyak waktu dan memerlukan uang. Selain itu, masih belum ada sistem deteksi jerawat yang dapat mendeteksi jerawat pada semua kondisi, biasanya diharuskan kulit terang dan kondisi cahaya yang baik.

Baru-baru ini, metode klasifikasi menggunakan Machine Learning mulai digunakan, untuk memberikan diagnosa pertama yang cepat. Tetapi, deteksi menggunakan machine learning masih memiliki masalah, yaitu deteksi pada kondisi lingkungan atau tone kulit yang berbeda. Proses deteksi kulit yang biasa digunakan adalah RGB, HSV, YCbCr, tetapi masing-masing memiliki kelemahan sendiri. RGB tidak bagus digunakan dikarenakan tercampurnya data *luminance* dan *chrominance*. YCbCr tidak memiliki masalah yang dimiliki RGB, tetapi masih terpengaruh dengan lingkungan dan tone kulit. HSV digunakan untuk memberikan lebih banyak kemudahan pada posisi jerawat yang di foto,

dengan menggabungkan HSV dan Grayscale. tetapi Warna, bentuk, dan pencahayaan akan berpengaruh besar bagi akurasi deteksi.

penggunaan CNN pada metode klasifikasi jerawat otomatis dengan menggunakan machine learning adalah salah satu cara yang bisa digunakan untuk membangun model deteksi jerawat. CNN sendiri telah digunakan secara massal untuk deteksi gambar menggunakan machine learning. terutama dikarenakan berkembangnya dataset *Imagenet*, CNN telah berkembang jauh dan adalah salah satu metode pembelajaran sistem yang baik bagi deteksi gambar. salah satu penggunaan CNN dalam pendeteksian jerawat adalah menggunakan arsitektur VGGNet, yang telah dilatih oleh dataset ImageNet. Sistem tersebut berhasil menghasilkan akurasi sebesar 90 persen[Shen et al. (2018)].

Maka dari itu, penelitian ini dilakukan untuk memberikan edukasi dan mempermudah deteksi 5 jenis Jerawat *Acne Vulgaris*, yaitu: Komedo hitam, Komedo Putih, Papula, Pustula, dan Kistik. pada kondisi tone kulit gelap hingga terang, menggunakan dataset yang disediakan oleh DermNet

1.2 Rumusan Masalah

Rumusan masalah pada penelitian ini adalah Bagaimana mendeteksi *acne vulgaris* pada kulit muka dengan tone atau warna kulit yang berbeda, dan dengan nilai akurasi minimal 85 persen?

1.3 Hipotesis

deteksi jerawat minimal 85 persen pada kondisi kulit gelap hingga terang

1.4 Batasan Masalah

Penelitian ini memiliki batasan yang meliputi:

1. aplikasi berbasis desktop
2. daerah deteksi adalah daerah muka
3. hanya tipe jerawat *acne vulgaris* yang akan dideteksi
4. analisa yang dilakukan hanyalah analisa akurasi deteksi terhadap tone kulit yang berbeda
5. tidak menggunakan live camera

1.5 Tujuan Penelitian

Tujuan dari penelitian ini adalah untuk menghasilkan model dan aplikasi yang dapat mendeteksi jerawat pada kondisi kulit apapun dengan akurasi minimal 85%

1.6 Manfaat Penelitian

Manfaat dari penelitian ini adalah ter-edukasinya masyarakat atas cara mengatasi jerawat dan tipe tipe jerawat yang dapat ditemui masyarakat.



BAB II

TINJAUAN PUSTAKA

penggunaan CNN pada metode klasifikasi jerawat otomatis dengan menggunakan machine learning adalah salah satu cara yang bisa digunakan untuk membangun model deteksi jerawat. CNN sendiri telah digunakan secara massal untuk deteksi gambar menggunakan machine learning. terutama dikarenakan berkembangnya dasaset *Imagenet*, CNN telah berkembang jauh dan adalah salah satu metode pembelajaran sistem yang baik bagi deteksi gambar

2.1 Jerawat

Jerawat adalah masalah kulit yang terjadi ketika folikel rambut atau tempat tumbuhnya rambut tersumbat oleh minyak dan sel kulit mati. Kondisi ini umumnya ditandai dengan munculnya bintik-bintik pada beberapa bagian tubuh, seperti wajah, leher, punggung, dan dada. Munculnya jerawat biasanya disebut juga dengan istilah breakout. Meski jerawat dapat dialami oleh siapa saja, namun sebagian besar kasus jerawat terjadi di masa puber, yaitu pada remaja berusia 10-13 tahun, dan semakin buruk pada orang dengan kulit berminyak. Terkadang, jerawat juga bisa muncul pada bayi dan anak-anak. Jerawat pada remaja umumnya akan hilang dengan sendirinya pada awal usia 20 tahun. Namun pada sebagian kasus, masih ada yang mengalami masalah jerawat hingga usia 30 tahun, terutama wanita.

2.2 Machine Learning

Teknologi machine learning (ML) adalah mesin yang dikembangkan untuk bisa belajar dengan sendirinya tanpa arahan dari penggunanya. Pembelajaran mesin dikembangkan berdasarkan disiplin ilmu lainnya seperti statistika, matematika dan data mining sehingga mesin dapat belajar dengan menganalisa data tanpa perlu di program ulang atau diperintah. Dalam hal ini machine learning memiliki kemampuan untuk memperoleh data yang ada dengan perintah ia sendiri. ML juga dapat mempelajari data yang ada dan data yang ia peroleh sehingga bisa melakukan tugas tertentu. Tugas yang dapat dilakukan oleh ML pun sangat beragam, tergantung dari apa yang ia pelajari. Machine learning memiliki beberapa tipe, yaitu Supervised learning, Unsupervised learning, dan Reinforced learning [Mitchell et al. (1997)].

2.2.1 Supervised Learning

Supervised Learning dalam bahasa indonesia adalah pembelajaran yang memiliki supervisor. Maksud supervisor disini adalah label di tiap data Label maksudnya adalah tag dari data yang ditambahkan dalam machine learning model. Contohnya gambar kucing di tag “kucing” di tiap masing masing image kucing dan gambar anjing di tag “anjing” di tiap masing gambar anjing. Machine learning kategori dapat berupa clasification (“anjing”, “kucing”, “beruang”, dsb) dan regression (berat badan, tinggi badan dsb)[Cunningham et al. (2008)].

2.2.2 Image Processing

Image Processing adalah suatu metode untuk mengolah gambar (Image) ke dalam bentuk digital untuk tujuan tertentu. Pada awalnya pengolahan citra ini berfungsi untuk memperbaiki dan meningkatkan kualitas suatu gambar, namun dengan perkembangan zaman dan munculnya ilmu-ilmu komputasi hal itu memungkinkan manusia dapat mengambil suatu informasi yang ada dalam suatu gambar. Inputnya adalah citra (gambar) dan keluarannya adalah citra yang sudah diperbagus kualitasnya. Misalnya, sebuah gambar yang kurang tajam warnanya, kabur (blurring) dan terdapat noise (mis bintang putih) memerlukan proses untuk memperbaiki kualitas gambar sehingga mendapatkan informasi yang lebih baik[Lézoray et al. (2008)].

2.2.3 Convolutional Neural Network(CNN)

Convolutional Neural Network adalah salah satu metode machine learning dari pengembangan Multi Layer Perceptron (MLP) yang didesain untuk mengolah data dua dimensi. CNN termasuk dalam jenis Deep Neural Network karena dalamnya tingkat jaringan dan banyak diimplementasikan dalam data citra. CNN memiliki dua metode; yakni klasifikasi menggunakan feedforward dan tahap pembelajaran menggunakan backpropagation. Cara kerja CNN memiliki kesamaan pada MLP, namun dalam CNN setiap neuron dipresentasikan dalam bentuk dua dimensi, tidak seperti MLP yang setiap neuron hanya berukuran satu dimensi[Albawi et al. (2017)].

2.2.4 VGGNet

VGGnet adalah sebuah arsitektur machine learning yang diciptakan oleh *Visual Geometry Group* dari *Oxford University* yang diusulkan oleh Karen Simonyan dan Andrew Zisserman. Arsitektur ini dilatih menggunakan dataset ImageNet pada perlombaan ILSVRC (*ImageNet Large Scale Visual Recognition Competition*) pada tahun 2014 dan berhasil mendapatkan posisi runner up pada perlombaan ILSVRC. Arsitektur ini memiliki ciri khas dalam menggunakan 3x3 convolutional layer yang ditumpuk satu sama lain untuk menambah *depth*, mengurangi ukuran volume menggunakan max pooling, dan layer yang terhubung penuh pada akhir network sebelum *softmax classifier* [Simonyan and Zisserman (2014)].

2.3 Confusion Matrix

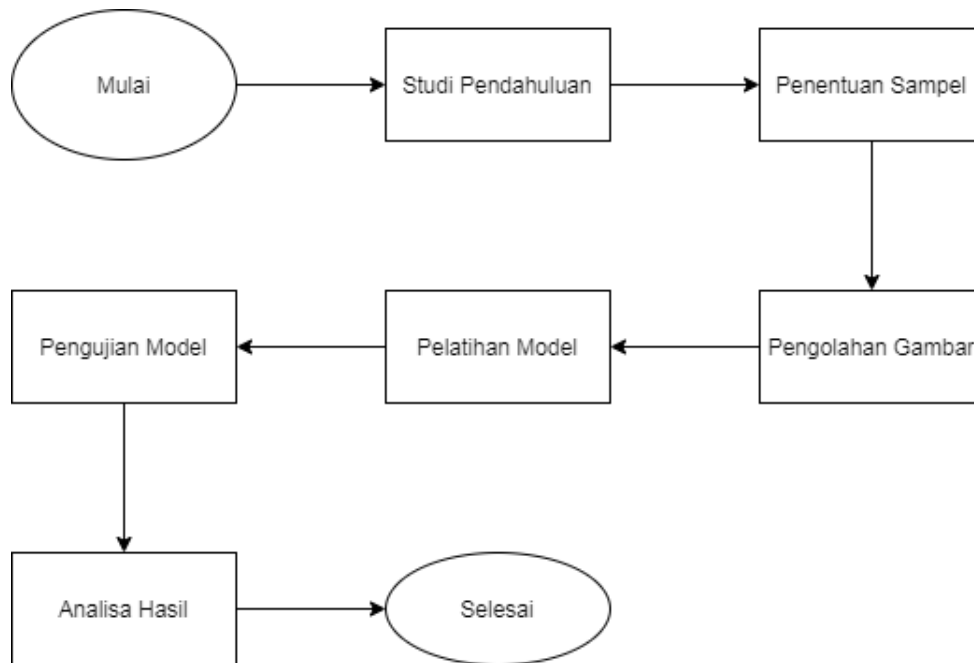
Confusion matrix digunakan sebagai acuan hasil evaluasi permasalahan klasifikasi. confusion matrix sendiri adalah pengukuran performa untuk klasifikasi machine learning yang memiliki 2 atau lebih kelas sebagai *output*. confusion matrix adalah tabel dengan 4 kombinasi berbeda dari nilai prediksi dan nilai asli, yaitu *True Positive*, *true negative*, *False Positive*, dan *true Negative* [Caelen (2017)].



Universitas
Pertamina

BAB III

METODE PENELITIAN



Gambar 3.1. Diagram proses penelitian.

Penelitian ini dilakukan dengan alur seperti yang terlihat pada Gambar 3.1. Penelitian diawali dengan studi pendahuluan. Pada proses ini, beberapa literatur dipelajari untuk dijadikan acuan. Kemudian, berdasarkan permasalahan yang akan diselesaikan, penelitian ini menentukan dan mengambil sampel data. Pengambilan sampel untuk model data dilakukan dengan cara Convenience Sampling, yaitu pengambilan sampel berdasarkan kemudahan untuk mendapatkannya[Sedgwick (2013)]. Convenience sampling dipilih atas dasar kemudahan dan kenyamanan dalam mengumpulkan sampel dengan efisien dengan waktu yang terbatas.

Proses pengumpulan sampel dilakukan dengan cara mencari dataset gambar jerawat yang tersedia secara open di kaggle. lalu di unduh dan dipisahkan ke 5 kategori, yaitu *Blackheads*, *Whiteheads*, *Papule*, *Pustule*, dan *cyst*. setelah proses pengumpulan dilakukan proses pengolahan gambar dengan augmentasi, yaitu dengan memutar, melakukan *resize* pada gambar, melakukan *zoom in* kepada gambar, dan melakukan horizontal flip. lalu, Proses pelatihan model dilakukan dengan library Tensorflow dan Keras, dengan menggunakan arsitektur VGGnet. dengan pembagian 80% dataset untuk training dan 20% untuk testing.

Hasil dari penelitian ini adalah sebuah model klasifikasi gambar yang dapat melakukan deteksi terhadap jerawat pada tone kulit yang berbeda dengan akurasi minimal 85%. Pengujian model dilakukan dengan menggunakan metric pengukuran confusion matrix dan melakukan pengujian akurasi dengan gambar yang telah disediakan. analisa hasil akan dilakukan dengan membandingkan akurasi

dari 3 gambar jerawat pada warna kulit berbeda yang telah disediakan pada masing masing tipe jerawat



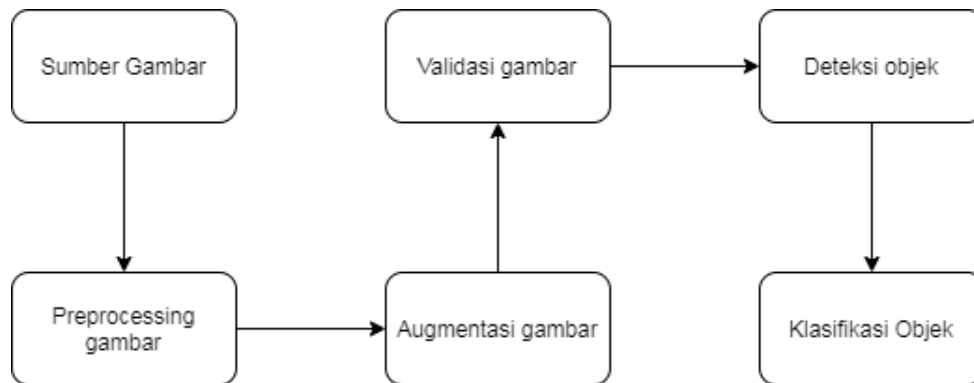
BAB IV

HASIL DAN PEMBAHASAN

4.1 Dataset


Dataset untuk penelitian ini diambil dari kaggle, dataset berisi gambar jerawat pada muka yang telah diberi label. *Pra-processing* data yang dilakukan adalah dengan melakukan pemutaran gambar, lalu resize gambar, lalu melakukan zoom gambar, dan terakhir melakukan flip gambar secara horizontal. Dataset dibagi menjadi 80% untuk data training, dan 20% untuk testing.

4.2 Training model




Gambar 4.1. Diagram sistem.

pertama, dilakukan preprocessing dan augmentasi terhadap gambar jerawat. gambar akan di ubah menjadi ukuran 96x96 yang memiliki depth sebesar 3. dimulai dengan filtering ukuran 32x32 dan layer 3x3. lalu filtering gambar akan diubah menjadi 64x64 dengan layer 2x2 untuk mengurangi *overfitting*. dan terakhir filter 128x128 digunakan dengan dropout 25% untuk sekali lagi mengurangi *overfitting*. terakhir, dilakukan kembali dropout 50% untuk penyelesaian validasi. setelah melewati proses preprocessing dan augmentasi, sistem akan melakukan validasi dan deteksi bahwa gambar tersebut adalah gambar jerawat. terakhir akan dilakukan klasifikasi terhadap tipe jerawat yang telah dideteksi oleh sistem.



Gambar 4.2. Nilai akurasi pada training dan Testing set.



Gambar 4.3. F1 Score pada training dan Testing set.

Setelah melakukan run epoch 125/125 hasil performa model training jerawat seperti yang ditunjukkan 4.2 memiliki akurasi sebesar 0.8831, atau 88.31% pada Training Set, dan 0.4500 atau 45% pada testing set. lalu seperti yang ditunjukkan oleh gambar 4.3 model memiliki f1 score sebesar 0.8687 atau 86.87% pada Training set, dan 0.3655 atau 36.55% pada testing set. akurasi dan F1 score pada training set cukup tinggi, dikarenakan dataset yang digunakan jauh dibawah rekomendasi jumlah dataset yang disarankan untuk melakukan pembelajaran klasifikasi gambar. dan sudah melewati hipotesis yang telah ditentukan. tetapi akurasi dan F1 score pada testing set dibawah nilai yang diinginkan

4.3 Hasil Klasifikasi

4.3.1 Whitehead/Komedo putih



Gambar 4.4. Hasil deteksi Komedo Putih pada kulit terang.




Gambar 4.5. Hasil deteksi Komedo Putih pada kulit gelap.

dapat dilihat pada perbandingan gambar komedo putih pada Gambar 4.4 dan pada gambar 4.5, hasil deteksi pada kulit terang menghasilkan akurasi yang tepat, sedangkan hasil deteksi pada kulit gelap teridentifikasi sebagai kista

4.3.2 Blackhead/Komedo Hitam




Gambar 4.6. Hasil deteksi Komedo hitam pada kulit terang.



Gambar 4.7. Hasil deteksi Komedo hitam pada kulit putih.

dapat dilihat pada perbandingan gambar komedo hitam pada Gambar 4.7 dan pada gambar 4.6, hasil deteksi pada kulit terang menghasilkan akurasi yang salah, deteksi menjadi komedo putih. sedangkan hasil deteksi pada kulit kecoklatan menghasilkan deteksi yang benar

4.3.3 Cyst/Kista



Gambar 4.8. Hasil deteksi Kista pada kulit terang.



Gambar 4.9. Hasil deteksi kista pada kulit gelap.

dapat dilihat pada perbandingan gambar kista pada Gambar 4.8 dan pada gambar 4.9, hasil deteksi keduanya berhasil mendeteksi kista dengan benar, tetapi kepastian program dalam mendeteksi bahwa itu kista lebih tinggi di kulit gelap dibanding kulit terang

4.3.4 Papula



Gambar 4.10. Hasil deteksi Papula pada kulit terang.



Gambar 4.11. Hasil deteksi papula pada kulit gelap.

dapat dilihat pada perbandingan gambar papula pada Gambar 4.10 dan pada gambar 4.11, hasil deteksi pada kedua warna kulit tidak berhasil dilakukan secara tepat, sistem mendeteksi papula sebagai jerawat kista

4.3.5 Pustula



Gambar 4.12. Hasil deteksi pustula pada kulit terang.



Gambar 4.13. Hasil deteksi pustula pada kulit gelap.

dapat dilihat pada perbandingan gambar pustula pada Gambar 4.12 dan pada gambar 4.13, hasil deteksi pada kedua kulit menghasilkan hasil yang tepat, tetapi pada kulit gelap sistem hanya bisa meyakini bahwa itu 43.47% pustula



BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

hasil analisa terhadap pengaruh perbedaan tone atau warna kulit terhadap sistem pendeteksian jerawat menggunakan arsitektur Small VGGNet menunjukan bahwa pengaruh tone kulit masih menjadi salah satu faktor yang sangat berpengaruh dalam kemampuan deteksi jerawat. selain itu juga, faktor seperti jumlah dataset, pencahayaan foto untuk klasifikasi, dan kejelasan foto itu sendiri

5.2 Saran

berikut adalah beberapa saran yang dapat membantu penelitian selanjutnya

1. Dataset yang lebih banyak
2. tone kulit yang berbeda pada dataset
3. foto untuk melakukan pengecekan klasifikasi yang memiliki gambar jelas dengan pencahayaan yang terang



Universitas
Pertamina

DAFTAR PUSTAKA


- Albawi, S., Mohammed, T. A., and Al-Zawi, S. (2017). Understanding of a convolutional neural network. In *2017 International Conference on Engineering and Technology (ICET)*, pages 1–6. Ieee.
- Caelen, O. (2017). A bayesian interpretation of the confusion matrix. *Annals of Mathematics and Artificial Intelligence*, 81(3):429–450.
- Cunningham, P., Cord, M., and Delany, S. J. (2008). Supervised learning. In *Machine learning techniques for multimedia*, pages 21–49. Springer.
- Jablonski, N. G. (2004). The evolution of human skin and skin color. *Annu. Rev. Anthropol.*, 33:585–623.
- Lézoray, O., Charrier, C., Cardot, H., and Lefèvre, S. (2008). Machine learning in image processing.
- McGrath, J., Eady, R., and Pope, F. (2004). Anatomy and organization of human skin. *Rook's textbook of dermatology*, 1:3–2.
- Mitchell, T. M. et al. (1997). Machine learning.
- Sedgwick, P. (2013). Convenience sampling. *Bmj*, 347.
- Shen, X., Zhang, J., Yan, C., and Zhou, H. (2018). An automatic diagnosis method of facial acne vulgaris based on convolutional neural network. *Scientific reports*, 8(1):1–10.
- Simonyan, K. and Zisserman, A. (2014). Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*.
- Williams, H. C., Dellavalle, R. P., and Garner, S. (2012). Acne vulgaris. *The Lancet*, 379(9813):361–372.
- Xiong, Z., Liveris, A. D., and Cheng, S. (2004). Distributed source coding for sensor networks. *IEEE Signal Processing Magazine*, 21(5):80–94.



LAMPIRAN A

Empirical Binary Entropies for Given Bit-Flipping Probabilities

With simulation setup given in Figure A.1, the empirical binary entropies for given bit-flipping probabilities are shown in Figure 2 (Xiong et al., 2004).



Gambar A.1. System setup for obtaining p_{ABC} .